

Relatório 01 - O que são dados sintéticos?

Ana Clara Fortunato de Souza

Descrição da atividade

O que são dados sintéticos?

Dados sintéticos são informações geradas artificialmente por algoritmos de computador e que não existem no mundo real. Apesar de serem artificiais elas refletem dados reais e são tão eficientes ou até melhores para treinar um modelo de IA do que dados baseados em objetos, eventos ou pessoas reais e, por isso, não devem ser entendidos simplesmente como dados falsos.


O objetivo é reproduzir, de maneira controlada, propriedades relevantes dos dados reais, como distribuições, relações entre variáveis, padrões visuais e situações operacionais. Dessa forma, eles podem ser utilizados em análises, testes e treinamentos de modelos de aprendizado de máquinas.

Existem diversos métodos em dados sintéticos protegem informações sensíveis, ao mesmo tempo que preservam importantes insights estatísticos dos seus dados originais e que podem atender às suas necessidades, porém podemos destacar três tipos de dados sintéticos:

1. **Dados totalmente sintéticos:** são inteiramente artificiais, mas preservam características e padrões estatísticos dos dados reais.
2. **Dados parcialmente sintéticos:** substituem apenas informações sensíveis por valores artificiais, mantendo os demais dados reais.
3. **Dados sintéticos híbridos:** combinam dados reais e artificiais para equilibrar privacidade, realismo e utilidade.

Observa-se uma tendência de crescimento no uso de dados sintéticos em sistemas de IA. Segundo a IBM Technology, há uma previsão de redução de aproximadamente 70% na utilização de dados reais a partir de 2025. Além disso, a Gartner estima que, até 2030, os dados sintéticos poderão superar os dados reais. Essas projeções reforçam a importância dessa tecnologia para reduzir custos, preservar a privacidade e contornar a escassez de dados.

By 2030, Synthetic Data Will Completely Overshadow Real Data in AI Models



Os dados sintéticos se tornarão a principal forma de dados usada na AI. Fonte: Gartner, "Pesquisa Maverick: Forget About Your Real Data – Synthetic Data Is the Future of AI," Leinar Ramos, Jitendra Subramanyam, 24 de junho de 2021.

Usos e benefícios:

É possível usar os dados sintéticos em várias áreas como saúde, finanças, robótica, veículos autônomos, segurança, indústria, visão computacional e desenvolvimento de software. Na saúde, por exemplo, é possível usar um conjunto de dados sintéticos para ajudar as empresas farmacêuticas a acelerar o desenvolvimento de medicamentos.

Os dados sintéticos permitem gerar grandes volumes de informações com mais rapidez e menor custo, reduzindo a necessidade de coleta e rotulagem manual. Também ajudam a preservar a privacidade, pois possibilitam realizar testes e análises sem expor diretamente informações pessoais ou confidenciais.

Além disso, permitem criar situações raras, extremas ou perigosas de maneira controlada, aumentando a diversidade dos conjuntos de treinamento. Essa abordagem pode corrigir desequilíbrios entre classes, gerar rótulos automaticamente e melhorar a capacidade de generalização dos modelos de inteligência artificial.

Na tabela a seguir podemos ver algumas diferenças entre Dados Reais e Dados Sintéticos:

Característica	Dados reais	Dados sintéticos
Origem	Coletados no mundo real	Gerados por algoritmos ou simulações
Custo de obtenção	Pode ser elevado	Pode ser menor após a configuração do processo
Privacidade	Pode conter informações pessoais	Pode reduzir a exposição de dados pessoais
Casos raros	Geralmente difíceis de encontrar	Podem ser criados de forma controlada
Rotulagem	Frequentemente manual	Pode ser automática
Realismo	Representa diretamente a realidade	Depende da qualidade do método utilizado
Escalabilidade	Limitada pela coleta	Pode permitir grande volume de dados

Fonte: elaborado pela autora (2026).

Desafios dessa abordagem:

Apesar das vantagens, os dados sintéticos podem não representar toda a complexidade do mundo real, especialmente quando o modelo de geração ou a simulação não considera características importantes. Também podem reproduzir ou ampliar vieses presentes nos dados originais, prejudicando a diversidade e a qualidade dos resultados.

Outro desafio é garantir a fidelidade estatística e visual, além da proteção das informações sensíveis. Por isso, é necessário escolher corretamente o método de geração, definir métricas de qualidade e validar os dados antes de utilizá-los em aplicações reais.


Entre os principais desafios estão:

- Manter a fidelidade estatística e visual;
- Evitar a reprodução ou ampliação de vieses;
- Representar casos complexos do mundo real;
- Escolher corretamente o método de geração;
- Definir métricas de qualidade;
- Validar os dados antes de utilizá-los;
- Garantir diversidade suficiente;
- Proteger as informações presentes na base original.

Geração:

A geração de dados sintéticos pode ser dividida nas seguintes etapas:

- **Definir o tipo de dado:** determinar se serão gerados textos, imagens, vídeos, áudios ou dados tabulares.
- **Identificar as fontes:** selecionar dados reais, regras, modelos estatísticos ou simulações que servirão como referência.
- **Estabelecer as especificações:** definir quantidade, formato, diversidade, classes e nível de realismo desejado.
- **Escolher o método:** selecionar a técnica mais adequada, como simulações, métodos estatísticos ou modelos de inteligência artificial.
- **Gerar os dados:** produzir as amostras conforme os requisitos estabelecidos.
- **Avaliar e validar:** verificar a qualidade, a diversidade, a privacidade e a semelhança dos dados sintéticos com os reais.



Fonte: elaborado pela autora (2026).

A geração de dados sintéticos começa com a definição do tipo de dado e do objetivo da aplicação. Em seguida, são identificadas as fontes de referência e estabelecidas especificações como formato, quantidade, diversidade, distribuição das classes e nível de realismo.

Depois, escolhe-se o método de geração, que pode utilizar técnicas estatísticas, simulações ou modelos de inteligência artificial. Por fim, os dados produzidos devem ser avaliados e validados para verificar sua qualidade, representatividade, privacidade e adequação ao uso pretendido.

Dificuldades

Nenhuma.

Conclusões

Os dados sintéticos são uma alternativa relevante para o desenvolvimento de sistemas de inteligência artificial, pois permitem ampliar conjuntos de treinamento, representar situações raras, reduzir custos e proteger informações sensíveis. Entretanto, sua eficácia depende de uma geração bem planejada e de uma validação cuidadosa, pois dados pouco representativos podem reproduzir vieses e comprometer o desempenho dos modelos.

Por isso, a combinação entre dados sintéticos e reais pode proporcionar resultados mais diversos, confiáveis e próximos da realidade. Com o crescimento dessa tecnologia, compreender suas aplicações, limitações e formas de avaliação será cada vez mais necessário.

Referências

IBM TECHNOLOGY. **What is synthetic data? No, it's not "fake" data**. YouTube, 29 mar. 2023. 1 vídeo (6 min 48 s). Disponível em: <https://youtu.be/HlusawrGBN4>. Acesso em: 20 jul. 2026.

ANDREWS, Gerard. O que são dados sintéticos? **Blog da NVIDIA**, 20 jul. 2021. Disponível em: <https://blog.nvidia.com.br/blog/o-que-sao-dados-sinteticos/>. Acesso em: 20 jul. 2026.

AMAZON WEB SERVICES. O que são dados sintéticos? **Amazon Web Services**. Disponível em: <https://aws.amazon.com/pt/what-is/synthetic-data/>. Acesso em: 20 jul. 2026.

BHOSALE, Uttkarsha; KAPADIA, Anupama. Synthetic data vs real data: benefits, limitations, and predictions for 2030. **Enago Academy**, 11 jan. 2024. Atualizado em: 20 mar. 2024. Disponível em: <https://www.enago.com/academy/synthetic-data-predictions-2030/>. Acesso em: 20 jul. 2026.