

Relatório 04 - Domain gap

Ana Clara Fortunato de Souza

Descrição da atividade

Introdução

O crescimento das aplicações de Inteligência Artificial e Visão Computacional aumentou significativamente a necessidade de grandes conjuntos de dados rotulados para treinamento de redes neurais profundas. Entretanto, coletar imagens reais e realizar sua anotação manual é uma tarefa cara, demorada e, geralmente, inviável.

Nesse contexto, os dados sintéticos surgem como uma alternativa capaz de gerar automaticamente milhares de imagens acompanhadas de suas respectivas anotações. Apesar dessa vantagem, existe um desafio conhecido como **Reality Gap**, que representa a diferença entre os ambientes simulados e o mundo real. Como consequência, modelos treinados exclusivamente em simulação costumam apresentar queda de desempenho quando aplicados em cenários reais.

Os três artigos estudados apresentam diferentes estratégias para reduzir essa lacuna, destacando principalmente as técnicas de **Domain Randomization** e **Domain Adaptation**.

O problema do Reality Gap

Mesmo os simuladores mais modernos ainda não conseguem reproduzir perfeitamente diversos fatores presentes no mundo real, como:

- iluminação;
- sombras;
- reflexos;
- ruídos da câmera;
- imperfeições das superfícies;
- desgaste dos objetos;
- variações climáticas.

Se a rede neural aprender essas características específicas da simulação, ela terá dificuldade para reconhecer objetos reais. Foi justamente esse problema que motivou os trabalhos estudados.




Figura 1 – Representação conceitual do Reality Gap entre o ambiente de simulação e o mundo real.

Fonte: Elaborado pela autora com base em Tobin et al. (2017), Tremblay et al. (2018) e Zhang et al. (2019).

Artigo 1 – Training Deep Networks with Synthetic Data (Tremblay et al.)

O trabalho da NVIDIA possui como principal objetivo verificar se imagens sintéticas simples podem substituir conjuntos de dados reais durante o treinamento de detectores de objetos. A principal técnica utilizada é a Domain Randomization (DR).

Ao invés de produzir cenários extremamente realistas, os autores modificam constantemente praticamente todos os parâmetros da cena.

Entre eles:

- Posição dos veículos;
- Modelos 3D utilizados;
- Texturas;
- Iluminação;
- Posição da câmera;
- Ângulo da câmera;
- Plano de fundo;
- Objetos distratores ("Flying Distractors").

Uma característica interessante é que muitas texturas utilizadas sequer tentam imitar o mundo real. O objetivo é justamente impedir que a rede memorize detalhes específicos da simulação.

Os experimentos mostraram que aumentar a quantidade de randomizações melhora significativamente o desempenho do detector, evidenciando que a diversidade da simulação é mais importante que seu realismo.




Figura 2 – Pipeline de geração das imagens utilizando Domain Randomization.

Artigo 2 – Synthetic-to-Real Domain Adaptation (Zhang et al.)

Enquanto o artigo anterior procura aumentar a diversidade dos dados sintéticos, Zhang propõe uma abordagem diferente.

Após treinar o modelo com imagens sintéticas, os autores utilizam uma técnica chamada Feature Adaptation Module (FAM) para aproximar matematicamente as características aprendidas da distribuição encontrada nas imagens reais.

O módulo é dividido em três partes:

GFAM	Responsável pelo alinhamento das características globais das imagens.
LFAM	Realiza a adaptação das características dos próprios objetos, como aparência, escala e formato.
SFAM	Alinha as máscaras utilizadas na segmentação das instâncias.

Os três módulos trabalham utilizando aprendizado adversarial. Durante o treinamento existe um discriminador tentando identificar se determinada característica veio do domínio sintético ou do domínio real. Ao mesmo tempo, a rede tenta produzir características tão semelhantes que o discriminador não consiga mais diferenciá-las.

Quando isso acontece, considera-se que houve adaptação entre os dois domínios.




Figura 3 – Arquitetura do Feature Adaptation Module (FAM).

Artigo 3 – Domain Randomization for Transferring Deep Neural Networks (Tobin et al.)

O terceiro trabalho apresenta uma das primeiras demonstrações de que uma rede neural pode ser treinada exclusivamente com imagens sintéticas RGB e ainda assim funcionar diretamente em um robô real. O objetivo não era detectar veículos, mas localizar objetos geométricos em coordenadas tridimensionais.

Durante o treinamento foram utilizados objetos como:

- Cone;
- Cubo;
- Cilindro;
- Pirâmide;
- Tetraedro;
- Prisma triangular;
- Prisma retangular;
- Prisma hexagonal.

Assim como no trabalho anterior, diversos parâmetros do ambiente eram modificados aleatoriamente:

- Iluminação;
- Câmera;
- Posição dos objetos;
- Texturas;
- Objetos distratores.

O resultado foi bastante expressivo, alcançando aproximadamente 1,5 cm de erro médio, mesmo sem utilizar qualquer imagem real durante o treinamento.



Figura 4 – Processo de treinamento em simulação e teste no robô real.

Comparação entre os Artigos

Artigo	Principal técnica	Objetivo
Tremblay	Domain Randomization	Melhorar detectores utilizando cenas extremamente variadas
Zhang	Domain Adaptation	Aproximar características sintéticas das imagens reais
Tobin	Domain Randomization	Transferência direta da simulação para robôs reais

Embora utilizem estratégias diferentes, os três trabalhos possuem o mesmo propósito: reduzir o impacto da Reality Gap.

Aplicações

As técnicas apresentadas podem ser empregadas em diversos cenários:

- Veículos autônomos;
- Robótica industrial;
- Agricultura de precisão;
- Inspeção de equipamentos;
- Drones;
- Logística automatizada;
- Cidades inteligentes;
- Realidade virtual.

Principais aprendizados

Durante o estudo dos artigos, alguns pontos chamaram bastante atenção:

- Ambientes extremamente realistas não são obrigatórios para produzir modelos eficientes;
- Aumentar a diversidade dos dados sintéticos é mais importante que aumentar sua fidelidade visual;
- Pequenas quantidades de dados reais podem ser suficientes para melhorar significativamente modelos previamente treinados com dados sintéticos;
- A combinação entre Domain Randomization e Domain Adaptation representa uma estratégia bastante promissora para reduzir custos de criação de datasets.

Dificuldades

A principal dificuldade foi compreender como as duas técnicas estudadas, Domain Randomization e Domain Adaptation, se complementam, pois inicialmente ambas pareciam resolver exatamente o mesmo problema.

Após a leitura dos artigos foi possível perceber que a primeira atua durante a geração dos dados sintéticos, aumentando sua variabilidade, enquanto a segunda atua diretamente sobre as características aprendidas pela rede, aproximando as distribuições dos domínios sintético e real.

Conclusões

Os artigos demonstram que os dados sintéticos representam uma solução eficiente para reduzir o custo e o tempo necessários para construção de grandes bases de treinamento em Visão Computacional. Entre os aspectos que mais chamaram minha atenção está o fato de que cenas extremamente realistas não são indispensáveis para obter bons resultados. Em muitos casos, aumentar a diversidade da simulação por meio da Domain Randomization mostrou-se mais eficiente do que investir apenas em fidelidade gráfica.

Além disso, a utilização de técnicas de Domain Adaptation complementa esse processo ao reduzir as diferenças entre os domínios sintético e real, permitindo que modelos treinados em simulação sejam utilizados em aplicações reais com maior precisão. Essas abordagens possuem grande potencial para áreas como robótica, veículos autônomos, inspeção industrial e sistemas inteligentes, onde a obtenção de dados anotados é um dos principais desafios.

Referências

TOBIN, Josh *et al.* Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World. In: IEEE/RSJ INTERNATIONAL CONFERENCE ON INTELLIGENT ROBOTS AND SYSTEMS (IROS), 2017, Vancouver. **Proceedings [...]**. Vancouver: IEEE, 2017. p. 23–30.

TREMBLAY, Jonathan *et al.* Training Deep Networks with Synthetic Data: Bridging the Reality Gap by Domain Randomization. In: IEEE/CVF CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION WORKSHOPS (CVPR WORKSHOPS), 2018, Salt Lake City. **Proceedings [...]**. Salt Lake City: IEEE, 2018. p. 1082–1090.

ZHANG, Hui *et al.* Synthetic-to-Real Domain Adaptation for Object Instance Segmentation. In: INTERNATIONAL JOINT CONFERENCE ON NEURAL NETWORKS (IJCNN), 2019, Budapest. **Proceedings [...]**. Budapest: IEEE, 2019. p. 1–8.