

Relatório 6 - Pipeline com Blender para Visão Computacional

Ana Clara Fortunato de Souza

Descrição da atividade

Os dois vídeos desta atividade apresentam o Blender como uma ferramenta capaz de produzir datasets completos para visão computacional. O primeiro, apresentado por Adam Kelly, organiza essa capacidade em quatro conceitos: anotação, automação, escalabilidade e acessibilidade. O segundo, apresentado por Miaomiao Yuan na Blender Conference 2024, mostra como esses fundamentos podem ser aplicados à direção autônoma, com destaque para dados sintéticos híbridos e geração distribuída em nuvem.

A análise foi complementada com o Manual do Blender e estudos sobre randomização de domínio, composição de imagens e datasets sintéticos para veículos autônomos. O objetivo foi compreender não apenas como gerar muitas imagens, mas quais condições fazem com que elas se tornem dados confiáveis para treinamento de inteligência artificial.

Introdução

A geração de dados sintéticos transforma ambientes 3D em fontes controláveis de exemplos para treinamento e avaliação de modelos. Nesse contexto, o Blender deixa de ser apenas um software de modelagem e renderização: sua API Python, seus passes de renderização e a execução em modo background permitem construir um pipeline capaz de criar imagens variadas e fornecer o ground truth correspondente.

Uma renderização, sozinha, é apenas uma imagem. Para se tornar um dado supervisionado, ela precisa estar associada a informações corretas sobre o conteúdo da cena, como classe, caixa delimitadora, máscara, profundidade ou pose. Além disso, a distribuição das amostras deve representar as condições que o modelo encontrará no mundo real.



Figura 1. Síntese dos quatro pilares apresentados no primeiro vídeo.

Fonte: elaboração própria (2026).

Vídeo 1: Synthetic Datasets with Blender, Part III

Adam Kelly encerra a série mostrando que o diferencial dos datasets sintéticos não é apenas a liberdade visual do ambiente 3D, mas a capacidade de controlar as variáveis da cena e extrair informações exatas sobre cada amostra. Um exemplo importante é o de veículos observados por ângulos raros, como um carro capotado. Mesmo um detector treinado com muitos

automóveis pode falhar quando quase todos os exemplos mostram somente perspectivas usuais.

1. Anotação automática e ground truth

A anotação é o elo que transforma a imagem renderizada em dados de treinamento. Em imagens reais, caixas delimitadoras e máscaras frequentemente dependem de trabalho humano; profundidade por pixel, fluxo óptico e pose 3D exigem sensores ou processos adicionais. No Blender, a geometria, a câmera e as transformações dos objetos já estão definidas matematicamente na cena, permitindo produzir anotações alinhadas ao quadro.




Figura 2. Saídas obtidas a partir de uma mesma cena: imagem RGB, bounding box, segmentação e profundidade.
Fonte: elaboração própria (2026).

O Manual do Blender descreve os render passes como informações intermediárias extraídas separadamente da renderização. Passes de profundidade e índices, combinados aos valores internos da cena, permitem criar várias modalidades de ground truth. Ainda assim, é necessário converter as saídas para o formato esperado pelo treinamento, como COCO, YOLO ou um padrão próprio, além de validar a correspondência entre imagem e anotação.

2. Automação e diversidade controlada

A API Python do Blender permite alterar objetos, câmera, materiais, iluminação e parâmetros de renderização por código. Um script pode repetir o ciclo de configurar a cena, randomizar variáveis, renderizar, coletar as anotações e salvar os arquivos. Automatizar, porém, não significa randomizar sem critério. As distribuições devem representar variações plausíveis e relevantes para a tarefa.




Figura 3. Fluxo simplificado de geração e validação de um dataset no Blender.

Fonte: elaboração própria (2026).

A validação fecha esse ciclo. Caixas, máscaras, pose e profundidade precisam corresponder à imagem; classes e ângulos devem seguir a distribuição planejada; e o modelo treinado deve ser avaliado em dados reais independentes. Caso contrário, o pipeline pode apenas reproduzir um erro milhares de vezes.

3. Escalabilidade e acessibilidade

O Blender pode ser executado por linha de comando em modo background, sem abrir a interface gráfica. Isso facilita o uso de servidores, contêineres e fazendas de renderização. A carga pode ser dividida entre diferentes máquinas, desde que a versão da cena, o script, os ativos e as sementes aleatórias sejam registrados para garantir rastreabilidade.

A acessibilidade também é um ponto importante: o Blender é gratuito, de código aberto e multiplataforma. A integração com Python, a documentação e a comunidade permitem que estudantes e equipes pequenas comecem a experimentar sem custos de licença, embora ainda exista uma curva de aprendizagem envolvendo computação gráfica, programação e engenharia de dados.

Vídeo 2: Synthetic data generation for AI training

Na Blender Conference 2024, Miaomiao Yuan apresenta a geração de dados sintéticos sob três perspectivas complementares: aprendizado de máquina, computação gráfica e programação. Para o aprendizado de máquina, a qualidade e a diversidade dos exemplos moldam o comportamento do modelo. Para a computação gráfica, qualquer cena visualizável pode ser transformada em dados. Para a programação, tarefas bem definidas podem ser automatizadas e repetidas em escala.

1. Dados sintéticos híbridos

A abordagem híbrida utiliza uma imagem real como fundo e insere objetos 3D renderizados em primeiro plano. Ela reduz o trabalho de reconstruir ruas, edifícios e paisagens, preservando parte do realismo visual do ambiente. Ao mesmo tempo, mantém controle sobre o tipo, a quantidade, a pose e a aparência dos objetos adicionados.




Figura 4. Princípio dos dados sintéticos híbridos: fundo real combinado a objeto 3D.

Fonte: elaboração própria (2026).

A composição não é uma simples colagem. A câmera virtual deve ser compatível com a câmera que capturou o fundo; escala e perspectiva precisam fazer sentido; objetos devem ocupar regiões livres; e oclusões, sombras e iluminação precisam ser coerentes. A palestra descreve o uso de anotações 3D, inferência de modelos e regras humanas para sustentar essa coerência espacial.

A ideia se relaciona ao estudo Cut, Paste and Learn, de Dwibedi, Misra e Hebert (2017), que demonstrou a utilidade de inserir objetos em fundos variados para treinar detectores. O uso de objetos 3D amplia a liberdade para variar pose e iluminação, embora também aumente a exigência de alinhamento geométrico.

2. Geração distribuída em nuvem

A mesma automação executada localmente pode ser distribuída entre várias máquinas. Yuan relata um caso em que a produção passou de aproximadamente 2 mil para 100 mil quadros por dia, um ganho próximo de cinquenta vezes. Esse número não representa um limite universal do Blender; ele demonstra como um pipeline headless pode transformar capacidade computacional em volume de dados.

EXEMPLO DE ESCALABILIDADE CITADO NA BLENDER CONFERENCE 2024




Figura 5. Comparação do volume diário citado na Blender Conference 2024.

Fonte: elaboração própria com base em Yuan (2024).

A nuvem, entretanto, apenas repete com maior velocidade do que foi programado. Ela não corrige rótulos incorretos, vieses ou cenas incoerentes. Antes de escalar, é necessário testar as regras de geração, verificar amostras e monitorar a cobertura dos parâmetros.

3. Direção autônoma e casos raros

A direção autônoma evidencia a utilidade dos dados sintéticos porque sistemas de percepção precisam lidar com veículos, pedestres, sinalização, clima, horários, oclusões e situações perigosas que não podem ser provocadas deliberadamente em vias públicas. A revisão de Song et al. (2024) mostra que datasets reais são caros para coletar e rotular e não acompanham facilmente novas exigências de teste.

Dados reais continuam indispensáveis para revelar ruídos de sensores, reflexos, falhas de exposição, comportamentos humanos e combinações ambientais difíceis de modelar. Por isso, uma estratégia sólida combina grande volume sintético para cobertura com dados reais para calibração, ajuste fino e validação.

Comparação entre as abordagens

Critério	Totalmente sintético	Sintético híbrido	Totalmente real
Controle	Muito alto sobre toda a cena.	Alto sobre as inserções; limitado pelo fundo.	Baixo sobre eventos e condições.
Anotação	Automática a partir da cena.	Automática para inserções; pode exigir dados do fundo.	Manual ou obtida por sensores e modelos.
Casos raros	Criados sob demanda.	Inseridos em contextos reais.	Difíceis ou perigosos de capturar.
Risco	Domain gap e regras inválidas.	Incoerência de câmera, luz e oclusão.	Viés de coleta e cobertura insuficiente.

Tabela 1. Comparação entre dados totalmente sintéticos, híbridos e reais.

Fonte: elaboração própria (2026).

Não existe uma abordagem universalmente superior. A escolha depende da tarefa, da infraestrutura, do custo de renderização e da quantidade de dados reais já existentes. Em muitos projetos, as três fontes podem coexistir. O fator decisivo é verificar se o conjunto melhora o desempenho do modelo em um cenário real independente.

Vantagens e limitações

Vantagens

- Anotações automáticas e consistentes;
- controle de casos raros, perigosos ou pouco frequentes;
- repetibilidade, rastreabilidade e variação planejada;
- execução em servidores e nuvem;
- menor barreira de entrada com Blender e Python.

Limitações

- Diferença entre simulação e mundo real (domain gap);
- custo de ativos, renderização, armazenamento e transferência;
- dificuldade de reproduzir ruídos e efeitos de sensores reais;
- possibilidade de amplificar vieses e regras incorretas em escala;
- necessidade de validação contínua com dados reais.

Dificuldades

A principal dificuldade foi acompanhar os termos técnicos em inglês e compreender as diferenças entre automação, escalabilidade e diversidade. Também foi necessário entender como extrair, organizar e validar as anotações geradas pelo Blender.

Conclusões

Os dois vídeos mostram níveis diferentes do mesmo processo. Adam Kelly apresenta os recursos que tornam o Blender uma ferramenta de geração de datasets: anotações derivadas da cena, automação por Python, execução escalável e acesso aberto. Miaomiao Yuan

demonstra como esses recursos evoluem para um pipeline industrial voltado à direção autônoma, incluindo composição híbrida e geração distribuída em nuvem.

O principal aprendizado foi que um dataset sintético útil depende do equilíbrio entre quantidade, diversidade e qualidade do ground truth. A automação aumenta a produtividade, mas também pode amplificar erros; a nuvem amplia o volume, mas não substitui o planejamento; e o fotorrealismo, sozinho, não garante transferência para o mundo real.

Os dados híbridos aparecem como um meio-termo valioso porque preservam o realismo do fundo e permitem inserir objetos raros sob controle. Em contrapartida, exigem coerência de câmera, escala, luz e oclusão. De forma geral, o Blender oferece uma base acessível e programável para transformar cenas 3D em dados de treinamento, desde que o pipeline inclua rastreabilidade, validação e testes em dados reais.

Referências

IMMERSIVE LIMIT. **Synthetic Datasets with Blender, Part III**. YouTube, 26 ago. 2020. Disponível em: <https://www.youtube.com/watch?v=-BaSjNpYQ4A>. Acesso em: 31 jul. 2026.

YUAN, Miaomiao. **Synthetic data generation for AI training**. Blender Conference 2024, Amsterdã, 24 out. 2024. Disponível em: <https://conference.blender.org/2024/presentations/3825/>. Acesso em: 31 jul. 2026.

BLENDER FOUNDATION. **Passes. Blender Manual**. Disponível em: <https://docs.blender.org/manual/en/latest/render/layers/passes.html>. Acesso em: 31 jul. 2026.

BLENDER FOUNDATION. **Using Blender from the command line**. Blender Manual. Disponível em: https://docs.blender.org/manual/en/latest/advanced/command_line/index.html. Acesso em: 31 jul. 2026.

DWIBEDI, Debidatta; MISRA, Ishan; HEBERT, Martial. Cut, **Paste and Learn: Surprisingly Easy Synthesis for Instance Detection**. IEEE International Conference on Computer Vision, 2017, p. 1301-1310.

SONG, Zhihang et al. **Synthetic Datasets for Autonomous Driving: A Survey**. IEEE Transactions on Intelligent Vehicles, v. 9, n. 1, p. 1847-1864, 2024.

TOBIN, Josh et al. **Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World**. IEEE/RSJ International Conference on Intelligent Robots and Systems, 2017, p. 23-30.