

Relatório 11 - Leitura: Introdução a Modelos Generativos e Comparação com Blender (IV)

Ana Clara Fortunato de Souza

Descrição da atividade

1. Introdução

Este relatório apresenta os principais conhecimentos adquiridos com a leitura dos artigos Exploring One-Shot GANs for Efficient Synthetic Flower Image Creation, de Vandana, Senthil e Narasimhadhan (2025), e GAN Augmentation: Augmenting Training Data using Generative Adversarial Networks, de Bowles et al. (2018). Os trabalhos analisam duas aplicações complementares das Redes Adversariais Generativas (GANs): a criação de imagens de flores em um cenário de poucos dados e o aumento de conjuntos de treinamento para segmentação de imagens médicas.

O objetivo é compreender o funcionamento básico desses modelos, interpretar suas métricas e comparar sua forma de geração de dados com o pipeline baseado em Blender utilizado nos cards anteriores. A análise também considera o projeto prático da caneca, no qual foram produzidas imagens RGB e máscaras de segmentação por meio de uma cena 3D automatizada.

Além dos dois artigos, foram consultados o trabalho original de Goodfellow et al. (2014), a pesquisa sobre treinamento de GANs com poucos dados de Karras et al. (2020) e a documentação do Blender sobre passes de renderização e máscaras. Essas fontes ajudam a situar os resultados e a discutir limitações como sobreajuste, instabilidade e diferença entre dados sintéticos e reais.

2. Fundamentos dos modelos generativos

Modelos generativos procuram aprender padrões presentes em um conjunto de dados para produzir novas amostras plausíveis. Em uma GAN, dois modelos são treinados simultaneamente. O gerador transforma um vetor aleatório, chamado vetor latente, em uma imagem sintética. O discriminador recebe imagens reais e geradas e estima a origem de cada uma. O treinamento assume a forma de um jogo minimax: o discriminador melhora sua capacidade de detectar falsificações, enquanto o gerador recebe sinais de erro e aprende a enganá-lo.




Figura 1 - Funcionamento geral de uma GAN.

Fonte: elaboração própria, com base em Goodfellow et al. (2014).

Quando o processo converge adequadamente, o gerador não deveria apenas memorizar imagens do treinamento, mas representar características da distribuição observada, como formas, cores, texturas e combinações frequentes. Na prática, o equilíbrio é delicado. Um discriminador muito forte pode fornecer gradientes pouco úteis; um gerador pouco diverso pode cair em mode collapse, produzindo várias amostras semelhantes. Em conjuntos pequenos, também cresce o risco de o discriminador memorizar os exemplos reais.

A DCGAN substitui camadas totalmente conectadas por operações convolucionais, adequadas à estrutura espacial das imagens. Já a PGGAN aumenta progressivamente a resolução durante o treinamento, estratégia escolhida por Bowles et al. para lidar com imagens médicas de maior resolução.

3. Artigo 1 - Exploring One-Shot GANs for Efficient Synthetic Flower Image Creation

O primeiro artigo implementa uma DCGAN em Python e TensorFlow para gerar flores. Embora o título empregue a expressão one-shot, o experimento relatado utiliza 500 imagens. Portanto, o termo deve ser entendido, nesse trabalho, como uma proposta voltada a poucos dados, e não como treinamento literal com uma única imagem. As amostras foram redimensionadas para 64 x 64 pixels e receberam transformações como rotação, espelhamento horizontal e variações de cor.

3.1 Arquitetura e treinamento

O gerador recebe um vetor de ruído com 100 dimensões e usa convoluções transpostas, normalização em lote e ativações ReLU para produzir imagens. A última camada utiliza Tanh. O discriminador percorre o caminho inverso com convoluções, normalização em lote e Leaky ReLU, terminando em uma classificação real ou sintética. O treinamento ocorreu por 250 épocas, com lotes de 32 imagens e otimizador Adam. Segundo os autores, cada época durou, em média, 47,3 segundos.

3.2 Avaliação pela métrica FID

A Fréchet Inception Distance (FID) compara estatisticamente representações das imagens reais e sintéticas. Valores menores indicam maior proximidade entre as distribuições. A DCGAN proposta obteve FID 80,32, enquanto a GAN tradicional usada como referência alcançou 113,06. Os autores interpretam o resultado como melhoria aproximada de 29%. A comparação sugere que a arquitetura convolucional capturou melhor a organização espacial das flores.



Figura 2 - Comparação da FID: valores menores são melhores. Fonte: elaboração própria, com dados de Vandana, Senthil e Narasimhadhan (2025).

A FID, entretanto, não deve ser tratada como prova isolada de qualidade. Ela depende das características extraídas por uma rede pré-treinada, pode variar com o número de amostras e não demonstra, sozinha, se a classe correta foi preservada. A inspeção visual do artigo ainda revela imagens borradas e inconsistências. Assim, uma avaliação robusta deve combinar métricas de distribuição, diversidade, análise visual e desempenho em uma tarefa posterior.

Outro cuidado é a escassez de dados. Karras et al. (2020) mostraram que poucas imagens podem levar ao sobreajuste do discriminador e propuseram o Adaptive Discriminator Augmentation (ADA) para estabilizar esse cenário. Isso reforça que a proposta do artigo das flores é promissora, porém arquiteturas e técnicas modernas podem melhorar a confiabilidade do treinamento com poucos exemplos.

4. Artigo 2 - GAN Augmentation: Augmenting Training Data using Generative Adversarial Networks

O segundo artigo investiga GANs como complemento de datasets anotados. O domínio médico é especialmente relevante porque a coleta é limitada por custos, privacidade e disponibilidade de pacientes, enquanto a segmentação manual depende de especialistas. Os autores treinaram uma PGGAN com patches multicanais contendo a imagem e seu rótulo, de forma que cada amostra sintética preservasse a correspondência entre aparência e segmentação.

Foram avaliadas duas tarefas: segmentação de líquido cefalorraquidiano em tomografias computadorizadas e segmentação de hiperintensidades da substância branca em ressonâncias magnéticas. Os dados sintéticos foram adicionados ao treinamento de redes como UNet, UResNet e DeepMedic. O desempenho foi medido pelo Dice Similarity Coefficient (DSC), que quantifica a sobreposição entre a segmentação prevista e a referência; valores maiores indicam melhor resultado.

4.1 Resultados quantitativos

Os ganhos observados variaram entre 1 e 5 pontos percentuais de DSC e foram mais expressivos quando poucos dados reais estavam disponíveis. No experimento de tomografia

com apenas 10% dos dados reais, a UNet obteve DSC 75,1 sem aumento; 76,3 com GAN; 76,9 com rotação; e 78,4 com a combinação de GAN e rotação.




Figura 3 - DSC da UNet com 10% dos dados reais de tomografia. Fonte: elaboração própria, com dados de Bowles et al. (2018, Tabela 3).

O efeito combinado foi superior ao de cada técnica isolada. A explicação proposta é que os métodos acrescentam variações diferentes: transformações tradicionais podem extrapolar orientações e escalas conhecidas, enquanto a GAN interpola combinações dentro da distribuição aprendida. Desse modo, não são alternativas excludentes.

4.2 Limites e ponto de saturação

Adicionar mais dados sintéticos não melhorou todos os casos. Na tarefa de ressonância, com 100% dos dados reais, o DSC caiu de 66,0 para 65,5 com 50% de dados sintéticos adicionais e para 64,8 com 100% adicionais. O resultado evidencia um ponto de saturação: se a base real já representa bem a tarefa, amostras artificiais podem introduzir vieses ou ruído. Por isso, o volume sintético precisa ser decidido a partir de validação separada, e não pelo princípio de que mais imagens sempre significam melhor aprendizagem.

O artigo também destaca que a GAN foi mais útil em situações de escassez e desbalanceamento de classes. Ainda assim, quando existem dados reais em quantidade extremamente pequena, a própria GAN pode não aprender variedade suficiente. Surge, portanto, uma faixa de utilidade: deve haver dados reais suficientes para treinar o gerador, mas ainda pouca cobertura para que as novas amostras tragam ganho.

5. Comparação: aumento tradicional, GAN e Blender

As três abordagens produzem diversidade por mecanismos distintos. O aumento tradicional aplica regras conhecidas a imagens existentes. A GAN aprende padrões estatísticos dos exemplos reais. O Blender cria imagens a partir de uma representação explícita da cena, permitindo definir geometria, câmera, iluminação, materiais e posições.

Critério	Aumento tradicional	GAN	Blender
Origem	Transforma imagens existentes	Aprende a distribuição dos dados reais	Renderiza uma cena 3D parametrizada
Controle	Alto, porém limitado às transformações	Indireto e probabilístico	Alto sobre câmera, luz, geometria e materiais
Anotações	Herdadas e transformadas	Precisam ser condicionadas, geradas em conjunto ou revisadas	Automáticas e exatas a partir da cena
Ponto forte	Baixo custo e previsibilidade	Variações visuais difíceis de programar	Controle físico e variedade de cenários
Risco	Diversidade limitada	Instabilidade, viés, artefatos e mode collapse	Reality gap e custo de modelagem/renderização
Melhor uso	Complemento inicial quase universal	Poucos dados reais, após validação	Objetos/cenas modeláveis e rótulos precisos

Quadro 1 - Comparação entre métodos de ampliação e geração de dados.

Fonte: elaboração própria (2026).

No Blender, cada parâmetro da cena é conhecido. Isso permite obter, no mesmo render, imagem RGB, profundidade, normais e máscaras por objeto ou material. A documentação do Blender descreve passes como Object Index, Material Index e Cryptomatte para a criação de máscaras. Essa rastreabilidade é uma vantagem importante em visão computacional, pois reduz o custo de anotação manual e evita que a imagem fique separada do rótulo.

A GAN oferece menor controle explícito. Ela pode capturar texturas, imperfeições e combinações difíceis de programar, mas também pode gerar artefatos ou reproduzir vieses da base real. Em tarefas de segmentação, não basta produzir uma imagem convincente: é indispensável garantir que a máscara corresponda ao conteúdo. Bowles et al. resolveram isso treinando a PGGAN com imagem e rótulo no mesmo patch.

O Blender também apresenta limitações. A cena precisa ser modelada e configurada; a renderização consome tempo; e uma aparência excessivamente limpa pode ampliar o reality gap. A randomização de domínio reduz esse problema ao variar luz, câmera, fundo, pose, materiais e ruído. Portanto, a escolha não é simplesmente entre um método 'melhor' e outro 'pior', mas entre níveis diferentes de controle, custo e dependência de dados reais.

Insight central: dados sintéticos devem ser avaliados pelo efeito que produzem no modelo final. Realismo visual, FID ou quantidade de arquivos não substituem a validação na tarefa de interesse. Para segmentação, o indicador decisivo é o desempenho em imagens reais que não participaram do treinamento.

6. Aplicação ao projeto da caneca

Nos Cards 9 e 10 foi desenvolvido um pipeline no Blender para gerar imagens de uma caneca com quatro níveis de líquido - empty, mostly_empty, half_full e full - além de máscaras de

segmentação. Essa abordagem garante controle direto sobre o nível do líquido, a pose da caneca, a câmera e a iluminação. A classe e a máscara são conhecidas no momento da renderização, o que facilita a criação de um dataset consistente.

Uma GAN poderia complementar esse pipeline em uma etapa posterior, desde que existam imagens reais ou renderizações suficientemente diversas. Algumas possibilidades seriam aprender variações de textura da cerâmica, reflexos, ruídos de câmera, fundos e condições de iluminação difíceis de modelar manualmente. Entretanto, uma GAN não deveria alterar livremente a região do líquido sem preservar o rótulo da classe. Para isso, seriam necessárias técnicas condicionais ou a geração conjunta de imagem e máscara.

6.1 Pipeline híbrido sugerido

Um experimento futuro poderia seguir cinco etapas: (1) gerar imagens e máscaras no Blender; (2) coletar um pequeno conjunto real da caneca; (3) treinar uma GAN condicionada ou aplicar tradução de domínio para aproximar o estilo visual; (4) combinar dados reais, renderizados e gerados; e (5) comparar o modelo de segmentação em um conjunto de teste exclusivamente real.

Para isolar o efeito de cada fonte, seria recomendável treinar quatro versões: apenas dados reais; reais com aumento tradicional; reais mais Blender; e reais mais Blender e GAN. As mesmas divisões de treino, validação e teste devem ser mantidas. As métricas podem incluir IoU e Dice para segmentação, FID apenas como indicador complementar de aparência, além de inspeção de máscaras e análise por classe de nível de líquido.

O cenário híbrido reúne vantagens diferentes: o Blender fornece cobertura controlada e rótulos exatos; os dados reais ancoram o domínio de aplicação; e a GAN pode aproximar texturas e variações visuais. O principal risco é gerar muitas amostras parecidas ou inconsistentes e, com isso, piorar o equilíbrio do dataset. A inclusão deve depender de resultados medidos, como demonstrado pelo segundo artigo.

7. Principais conhecimentos adquiridos

A leitura permitiu compreender que GANs não são apenas geradores de imagens visualmente interessantes. Elas podem funcionar como instrumentos de aumento de dados, especialmente quando a coleta e a anotação são caras. Também ficou clara a diferença entre aprender variações a partir dos dados e defini-las manualmente em uma cena 3D.

Outro aprendizado foi a importância de interpretar métricas no contexto. Uma FID menor indica maior proximidade estatística, mas não garante utilidade para classificação ou segmentação. O DSC mede a tarefa final e mostrou que o benefício foi maior com poucos dados reais, além de revelar perdas quando o conjunto sintético foi acrescentado em excesso. Assim, a qualidade de um dataset depende de diversidade, coerência dos rótulos e capacidade de melhorar a generalização em dados reais.

Dificuldades

A principal dificuldade foi interpretar termos e métricas dos artigos em inglês, especialmente FID, DSC, PGGAN, vetor latente e treinamento adversarial. Também foi necessário comparar experimentos com objetivos diferentes: um avalia a aparência das flores geradas, enquanto o outro mede o impacto dos dados sintéticos na segmentação médica. A releitura das tabelas, a consulta a referências complementares e a organização dos resultados em gráficos facilitaram a compreensão.

Conclusões

Os artigos demonstram que GANs podem gerar imagens e ampliar datasets, mas seu valor depende do contexto. A DCGAN do estudo das flores alcançou FID 80,32, inferior ao valor 113,06 da GAN tradicional, indicando melhor aproximação da distribuição visual. No estudo médico, o aumento por GAN elevou o DSC principalmente quando havia poucos dados reais e apresentou sinergia com rotações tradicionais. Ao mesmo tempo, a queda observada na ressonância com todos os dados reais confirma que amostras sintéticas não garantem melhoria automática.

Em comparação, o Blender oferece maior controle sobre a formação da imagem e produz anotações precisas diretamente da cena, sendo adequado para o dataset da caneca. As GANs são úteis quando se deseja aprender variações visuais existentes no mundo real, porém apresentam menor controle e exigem validação rigorosa. A estratégia mais promissora é híbrida: combinar dados reais, renderizações controladas, aumento tradicional e geração aprendida, sempre medindo o desempenho em um conjunto real independente.

O principal insight do Card 11 é que a decisão não deve se basear apenas no realismo das imagens ou no tamanho final da pasta. Um dado sintético é realmente útil quando aumenta a diversidade relevante, mantém rótulos coerentes e melhora a capacidade do modelo de generalizar.

Referências

BOWLES, Christopher et al. **GAN Augmentation: Augmenting Training Data using Generative Adversarial Networks**. arXiv:1810.10863, 2018. Disponível em: <https://arxiv.org/abs/1810.10863>. Acesso em: 5 ago. 2026.

BLENDER FOUNDATION. **Passes. Blender Manual**. Disponível em: <https://docs.blender.org/manual/en/latest/render/layers/passes.html>. Acesso em: 5 ago. 2026.

GOODFELLOW, Ian et al. **Generative Adversarial Nets. Advances in Neural Information Processing Systems**, v. 27, 2014. Disponível em: <https://papers.nips.cc/paper/5423-generative-adversarial-nets>. Acesso em: 5 ago. 2026.

KARRAS, Tero et al. **Training Generative Adversarial Networks with Limited Data. Advances in Neural Information Processing Systems**, v. 33, 2020. Disponível em: <https://proceedings.neurips.cc/paper/2020/hash/8d30aa96e72440759f74bd2306c1fa3d-Abstract.html>. Acesso em: 5 ago. 2026.

VANDANA, S.; SENTHIL, Sugavanam; NARASIMHADHAN, A. V. **Exploring One-Shot GANs for Efficient Synthetic Flower Image Creation**. In: **INTERNATIONAL CONFERENCE ON ARTIFICIAL INTELLIGENCE IN INFORMATION AND COMMUNICATION (ICAIC)**, 2025. DOI: 10.1109/ICAIC64266.2025.10920723.